

Тема 1. ОБЩИЕ СВОЙСТВА СТАТИСТИЧЕСКИХ ОЦЕНОК

Теоретическое введение

Простейшая постановка задачи оценивания неизвестного параметра такова.

Пусть x_1, \dots, x_n — выборка, т.е. n независимых испытаний случайной величины X с функцией распределения $F(x; a)$, где a — параметр, значение которого неизвестно. Требуется по выборке оценить значение параметра.

Оценкой $\hat{a} = \varphi(x_1, \dots, x_n)$ называется **функция наблюдений**, используемая для приближенного определения неизвестного параметра. Значение \hat{a} оценки является случайной величиной, поскольку (x_1, \dots, x_n) — случайная величина, вообще говоря, многомерная.

Свойства оценок

1. Оценка $\hat{a} = \varphi(x_1, \dots, x_n)$ называется *состоятельной*, если при $n \rightarrow \infty$ $\hat{a} \rightarrow a$ по вероятности при любом значении a .

2. Оценка $\hat{a} = \varphi(x_1, \dots, x_n)$ называется *несмещенной*, если при любом a

$$M\hat{a} = M\varphi(x_1, \dots, x_n) = a.$$

Состоятельность — обязательное свойство используемых оценок. Свойство несмещенности является желательным; многие применяемые оценки свойством несмещенности не обладают.

3. Оценка φ^* называется *оптимальной*, если для неё средний квадрат ошибки

$$M(\hat{a} - a)^2 = M[\varphi^*(x_1, \dots, x_n) - a]^2 = \min M[\varphi(x_1, \dots, x_n) - a]^2 = R(a)$$

минимален среди всех оценок $\{\varphi\}$; здесь критерием качества оценки принят квадрат ошибки $(\hat{a} - a)^2$. В более общей ситуации критерием качества служит некоторая величина $L(\hat{a}, a)$, называемая функцией потерь. Ясно, что оптимальной оценки может не существовать (так как характеристикой является функция, а не число).

Примеры

Пример 1. С целью оценить дисперсию σ^2 выборка

$$\xi_1, \xi_2, \dots, \xi_n, \quad M\xi_i = m, \quad D\xi_i = \sigma^2 = ?,$$

Пример 1. Произведено 20 опытов над величиной X ; результаты приведены в таблице 14.3.2

Таблица 14.3.2

i	x_i	i	x_i	i	x_i	i	x_i
1	10,5	6	10,6	11	10,6	16	10,9
2	10,8	7	10,9	12	11,3	17	10,8
3	11,2	8	11,0	13	10,5	18	10,7
4	10,9	9	10,3	14	10,7	19	10,9
5	10,4	10	10,8	15	10,8	20	11,0

min=10.3,

max=11.3

подвергается обработке по *разностям соседних наблюдений*. Применяется следующая процедура:

$$\tilde{\sigma}^2 = k \cdot \sum_{j=1}^{n-1} (\xi_{j+1} - \xi_j)^2; \quad (1)$$

т.е. суммируются квадраты разностей «соседних» наблюдений. Очевидно, $M(\xi_{j+1} - \xi_j) = 0$, $M(\xi_{j+1} - \xi_j)^2 = D(\xi_{j+1} - \xi_j) = 2\sigma^2$.

Из лекционного курса хорошо известна несмещенная оценка s^2 для σ^2 :

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (\xi_i - \bar{\xi})^2, \quad \bar{\xi} = \frac{1}{n} \cdot \sum_{j=1}^n \xi_j \quad (2)$$

однако, она может нас не устраивать по вычислительной реализации, т.к. сначала нужно вычислить среднее, затем все отклонения от среднего, возвести их в квадрат, и квадраты просуммировать.

Процедура (1) более удобна в этом смысле: к предыдущей сумме добавляется очередное слагаемое. Ясно также, что, поскольку $M(\xi_{j+1} - \xi_j)^2$ пропорционально σ^2 , эта статистика оценивает величину разброса, надо лишь подобрать коэффициент k так, чтобы получить несмещенную оценку:

$$M\tilde{\sigma}^2 = \sigma^2 \quad (3)$$

Вычисляем $M\tilde{\sigma}^2$:

$$M\tilde{\sigma}^2 = k \cdot \sum_{j=1}^{n-1} M(\xi_{j+1} - \xi_j)^2 = k(n-1) \cdot M(\xi_{j+1} - \xi_j)^2 = k(n-1) \cdot 2\sigma^2$$

Из (3) получаем:

$$k \cdot (n-1) \cdot 2\sigma^2 = \sigma^2 \Rightarrow k = \frac{1}{2(n-1)}$$

Пример 2. Пусть $\xi_1, \xi_2, \dots, \xi_n$ — выборка; наблюдения подчиняются закону Пуассона: $\xi_i \sim Po(a)$, (напомним, $M\xi_i = m_1 = a$, $D\xi_i = \sigma^2 = a$). Параметр a неизвестен.

Оценить первые два момента. Первый момент m_1 совпадает с параметром, $m_1 = a = ?$, оценив m_1 (мы знаем, как оценивается первый момент), мы оценим параметр a .

$$\hat{a} = \hat{m}_1 = \frac{1}{n} \sum_{i=1}^n \xi_i = \bar{\xi}$$

Второй момент является функцией от параметра:

$$m_2 = D\xi_i + m_1^2 = a + a^2 = f(a) = ?$$

Подставив вместо a ее оценку \hat{a} , мы должны получить разумную оценку (это типичный способ рассуждений в статистике)

$$\hat{m}_2 = f(\hat{a}) = \hat{a} + \hat{a}^2 = \bar{\xi} + (\bar{\xi})^2 = \bar{\xi}(1 + \bar{\xi})$$

Проверим ее несмещённость:

$$M\hat{m}_2 = M \bar{\xi} + \bar{\xi}^2 = M\bar{\xi} + D\bar{\xi} + (M\bar{\xi})^2 = a + \left[\frac{a}{n} + a^2 \right] = (a + a^2) + \frac{a}{n} = m_2 + \frac{a}{n} \neq m_2,$$

т.е. оценка смещённая. Можно попытаться исправить ее, сделать несмещённой; для этого нужно избавиться от смещения a/n , но вычесть его из оценки мы не можем, поскольку значение a неизвестно; вычтем из оценки \hat{m}_2 такую случайную величину (СВ) X , у которой $MX = \frac{a}{n}$; в качестве такой X возьмем $X = \hat{a}/n = \bar{\xi}/n$. Новая оценка

$$\tilde{m}_2 = \hat{m}_2 - \frac{\bar{\xi}}{n} = \bar{\xi}(1 + \bar{\xi}) - \frac{\bar{\xi}}{n} = \frac{n-1}{n} \bar{\xi} + \bar{\xi}^2,$$

очевидно, оценка \tilde{m}_2 несмещённая:

$$M\tilde{m}_2 = M\hat{m}_2 - M\frac{\bar{\xi}}{n} = \left[(a + a^2) + \frac{a}{n} \right] - \frac{a}{n} = a + a^2 = m_2$$

Дополнительный вопрос: можно ли предложить другую несмещённую оценку? Можно, а именно, дежурную:

$$m_2^* = \frac{1}{n} \sum_{i=1}^n \xi_i^2, \quad Mm_2^* = m_2 = a^2 + a$$

Ну, и какая оценка более точная? Нужно сравнить дисперсии. ??? Не вдохновляет. Пока ответить не просто.

Однако, не вычисляя дисперсии, в нашем случае можно заранее сказать, что \tilde{m}_2 более точная, т.к. она основана на достаточной статистике $\bar{\xi}$.

Пример 3. Произведено $n=10$ выстрелов и получено $x=8$ попаданий. Количество попаданий — это СВ ξ , распределённая по биномиальному закону:

$$\xi \sim Bi(n, p), \text{ т.е. } P\{\xi = k\} = C_n^k p^k (1-p)^{n-k}.$$

Считая параметр p неизвестным, требуется предложить несмещённые оценки \hat{m} и $\hat{\sigma}^2$ для математического ожидания (МО)

$$m = np \quad \text{и дисперсии} \quad \sigma^2 = npq = np(1-p)$$

этого распределения,. Поступим аналогично тому, как это сделано в предыдущем примере. Мы знаем оценку для вероятности p :

$$\hat{p} = \frac{\xi}{n},$$

а m и σ^2 - функции p . Рассмотрим оценки

$$\hat{m} = n\hat{p} = n \frac{\xi}{n} = \xi \quad \text{и} \quad \hat{\sigma}^2 = n\hat{p}(1-\hat{p}) = \xi \left(1 - \frac{\xi}{n} \right) = \xi - \frac{\xi^2}{n}$$

Несмещённость первой очевидна:

$$M\hat{m} = M\xi = np = m.$$

Для второй имеем

$$M\hat{\sigma}^2 = M\left(\xi - \frac{\xi^2}{n}\right) = np - \frac{1}{n} D\xi + (M\xi)^2 = np - \frac{1}{n} npq + (np)^2 =$$

$$= np - np^2 - pq = npq - pq = (n-1)pq \neq npq$$

$\Rightarrow \hat{\sigma}^2$ смещённая оценка: мешает множитель $(n-1) \neq n$. Исправим введением подходящего множителя:

$$\tilde{\sigma}^2 = \frac{n}{n-1} \hat{\sigma}^2 = \frac{n}{n-1} \xi \left(1 - \frac{\xi}{n}\right);$$

оценка, конечно, несмещенная, проверим:

$$M\tilde{\sigma}^2 = \frac{n}{n-1} M\hat{\sigma}^2 = \frac{n}{(n-1)} (n-1)pq = npq = \sigma^2$$

Для нашего наблюдения $x = 80$: $\tilde{\sigma}^2 = \frac{10}{9} \cdot 8(1-0,8) = \frac{10}{9} \cdot 1,6$, $\tilde{\sigma} = \frac{4}{3}$

Для небольших n поправку $\frac{n}{n-1}$ нужно учитывать

Пример 4. Для определения вероятности события A производится n независимых опытов, в каждом из которых

$$P(A) \equiv p$$

одна и та же. Определить, при каком значении p дисперсия оценки вероятности будет максимальной.

Решение: ξ — число появлений случайного события A . Оценка

$$\hat{p} = \frac{\xi}{n}; \quad \xi \sim Bi(n, p)$$

$$D\hat{p} = D\frac{\xi}{n} = \frac{np(1-p)}{n^2} = \frac{p(1-p)}{n}$$

Это выражение достигает максимума при $p^* = \frac{1}{2}$.

Пример 5. Пусть $\xi_1, \xi_2, \dots, \xi_n$ — результаты независимых измерений неизвестной постоянной величины. Ошибки измерений подчиняются одному и тому же закону нормального распределения.

Стандартное отклонение σ ошибок измерений оценивается по формуле:

$$\hat{\sigma} = k \sum_{j=1}^n |\xi_j - \bar{\xi}|, \quad \text{где } \bar{\xi} = \frac{1}{n} \sum_{i=1}^n \xi_i$$

Определить значение коэффициента k , при котором оценка $\hat{\sigma}$ является несмещенной:

$$k = ? : M\hat{\sigma} = \sigma$$

Решение. Определим МО:

$$M\hat{\sigma} = k \sum_{j=1}^n M|\xi_j - \bar{\xi}| = knM|\xi_j - \bar{\xi}| = kn \cdot M|\eta|,$$

где обозначено $\eta \equiv \xi_j - \bar{\xi} \sim N(0, \sigma_1^2)$.

$M|\eta| = ?$, но σ_1^2 неизвестна, $\sigma_1^2 = ?$ - дисперсия разности зависимых
С.В..

Вынесем из средне-арифметического $\bar{\xi}$ слагаемое с номером j :

$$\eta \equiv \xi_j - \frac{\xi_j}{n} - \frac{1}{n} \sum_{i=1, i \neq j}^n \xi_i = \xi_j \frac{n-1}{n} - \frac{1}{n} \sum_{i=1, i \neq j}^n \xi_i,$$

чтобы иметь для η сумму независимых. Теперь для η имеем:

$$\begin{cases} M\eta = 0; \\ D\eta = \frac{n-1}{n}^2 \sigma^2 + \frac{1}{n^2} (n-1) \sigma^2 = \frac{\sigma^2}{n^2} (n-1) (n-1) + 1 = \sigma^2 \frac{n-1}{n} = \sigma_1^2. \end{cases}$$

$$\eta \sim N(0, \sigma_1^2 = \sigma^2 \frac{n-1}{n}).$$

Определим

$$\begin{aligned} M|\eta| &= \int_{-\infty}^{\infty} |y| \frac{e^{-y^2/2\sigma_1^2}}{\sqrt{2\pi\sigma_1^2}} dy = \frac{2}{\sqrt{2\pi\sigma_1^2}} \int_0^{\infty} y \cdot e^{-y^2/2\sigma_1^2} dy = \\ &= \frac{2}{\sqrt{2\pi\sigma_1^2}} \sigma_1^2 \int_0^{\infty} e^{-y^2/2\sigma_1^2} d\left(\frac{y^2}{2\sigma_1^2}\right) = \sigma_1 \frac{2}{\sqrt{2\pi}} \int_0^{\infty} e^{-z} dz = \sigma_1 \sqrt{\frac{2}{\pi}} \end{aligned}$$

Условие несмещенности:

$$\begin{aligned} M\hat{\sigma} &= kn \cdot M|\eta| = kn \sqrt{\frac{2}{\pi}} \cdot \sigma_1 = kn \sqrt{\frac{2}{\pi}} \cdot \sigma \sqrt{\frac{n-1}{n}} = \sigma. \\ k &= \frac{1}{n} \cdot \sqrt{\frac{\pi}{2}} \cdot \sqrt{\frac{n}{n-1}} = \sqrt{\frac{\pi}{2n(n-1)}} \end{aligned}$$

Домашнее задание: гл.19, №№ 102, 103, 104.

Сборник задач по математике для втузов. Ч.4. / Под редакцией А.В.Ефимова и А.С.Поспелова. М.: Изд. ФизМатЛит., 2003.- 423 с.